

Comparativa del coste idealizado de movimiento de datos
Atención naïve vs FlashAttention (head_dim = 128)

